

UNIVERSIDADE FEDERAL DA BAHIA
INSTITUTO DE FÍSICA
BACHARELADO EM FÍSICA

PABLO ROBERTO VÁSQUEZ DOS ANJOS

Índice de Qualidade do Ar

SALVADOR
2025

PABLO ROBERTO VÁSQUEZ DOS ANJOS

Índice de Qualidade do Ar

Relatório apresentado na
disciplina MATD40 - Análise de
Dados, como requisito parcial
de avaliação.

SALVADOR
2025

RESUMO

Palavras-chave: IQAR, Séries temporais, Imputação de dados, Bahia.

Este trabalho apresenta uma avaliação comparativa de métodos de imputação de dados em séries temporais de qualidade do ar, focando no monitoramento de estações localizadas no estado da Bahia (Camaçari, Dias d'Ávila e São Sebastião do Passé). Identificou-se uma limitação crítica no monitoramento local: nenhuma das estações analisadas realiza a medição simultânea dos seis poluentes regulamentados (SO_2 , NO_2 , O_3 , CO , MP_{10} e $\text{MP}_{2,5}$), o que torna o valor final do IQAR tecnicamente inconclusivo e potencialmente subestimado. Devido à ocorrência frequente de falhas nos sensores, o preenchimento de lacunas é essencial para a integridade do Índice de Qualidade do Ar (IQAR). A metodologia envolveu o pré-processamento de dados brutos, a consolidação do IQAR pelo critério do poluente crítico e a criação de lacunas artificiais (pontuais e intervalares) com distâncias temporais controladas para validação. Foram testados seis métodos: Interpolação Linear, Interpolação Polinomial (ordens 2 e 3), Média Móvel Exponencial Ponderada, KNN Imputer e SARIMAX. Os resultados indicam que a série apresenta persistência temporal e uma pequena sazonalidade diária, conforme evidenciado pelas funções de autocorrelação (ACF e PACF). O método de Interpolação Linear apresentou o melhor desempenho global, atingindo o maior Índice de Willmott ($d = 0,925$) e a maior eficiência de Nash-Sutcliffe ($\text{NSE} = 0,749$), seguido pelo modelo SARIMAX ($d = 0,908$). Conclui-se que, para a estrutura de dados analisada, métodos que exploram a continuidade imediata da série superam modelos de maior complexidade matemática na reconstrução de hiatos curtos e médios.

LISTA DE FIGURAS

Figura	Página
Figura 1 - Parâmetros atmosféricos medidos e suas respectivas unidades de medição.	11
Figura 2 - Fórmula do Índice de Qualidade do Ar.	11
Figura 3 - Valores de referência para o cálculo do IQAR.	12
Figura 4: Mapa das estações distribuídas pelo Brasil.	12

LISTA DE TABELAS

Tabela	Página
Tabela 1: Recorte da base de dados com todos os registros das estações de monitoramento.	11
Tabela 2: Descrição das estações de monitoramento do estado da Bahia.	12
Tabela 3: Recorte do dataframe com os dados do estado da Bahia.	12
Tabela 4: Resultados dos métodos de estimação.	28

LISTA DE ABREVIATURAS E SIGLAS

IQAR - Índice de Qualidade do Ar.

OMS - Organização Mundial da Saúde.

MMA - Ministério do Meio Ambiente.

CETREL - Central de Tratamento de Efluentes Líquidos.

INEMA - Instituto do Meio Ambiente e Recursos Hídricos.

SUMÁRIO

RESUMO	02
LISTA DE FIGURAS	03
LISTA DE TABELAS	04
LISTA DE ABREVIATURAS E SIGLAS	06
1. INTRODUÇÃO	08
2. METODOLOGIA	09 - 17
2.1 MATERIAL	09 - 12
2.2 MÉTODOS	12 - 17
3. RESULTADOS E DISCUSSÃO	18 - 28
4. CONCLUSÃO	29
5. REFERÊNCIAS BIBLIOGRÁFICAS	30
6. APÊNDICE/ANEXO	31

1. INTRODUÇÃO

O Índice de Qualidade do Ar (IQAR) é um indicador extremamente importante para a saúde pública e o bem-estar ambiental. Os poluentes atmosféricos considerados para medição deste índice estão associados ao agravamento de doenças cardiorrespiratórias e consequentemente ao aumento das taxas de mortalidade nas localidades onde o IQAR é alto. Esses impactos, além de custosos em termos sociais e econômicos, tornam o monitoramento contínuo da qualidade do ar uma ferramenta imprescindível para a formulação de políticas públicas, estratégias de mitigação e alertas à população. Em nível internacional, diretrizes e marcos regulatórios — como as diretrizes globais da OMS para qualidade do ar e legislações nacionais sobre padrões ambientais — têm orientado a medição, padronização e interpretação dos indicadores de poluição atmosférica (WHO, 2021).

O presente trabalho dedica-se justamente à análise deste IQAR em uma rede de estações de monitoramento localizadas no estado da Bahia, a base de dados foi extraída do portal de dados abertos do governo federal, postado pelo Ministério do Meio Ambiente (MMA) e compreende medições realizadas pela Central de Tratamento de Efluentes Líquidos (CETREL) e pelo Instituto do Meio Ambiente e Recursos Hídricos (INEMA), instituições que atuam de forma integrada na gestão ambiental do estado. O foco do estudo foi de conduzir uma análise exploratória do IQAR monitorado, acompanhada de procedimentos de tratamento e organização dos dados, com o objetivo de compreender a estrutura do conjunto de informações, o comportamento dessa variável, identificar padrões gerais, e possíveis inconsistências nos dados. Foram feitas também preliminares análises geoespaciais de correlação das estações, para finalmente realizar séries temporais e submetê-las a diferentes métodos de estimação temporal, buscando avaliar o desempenho de cada abordagem identificando o método mais eficiente.

2. METODOLOGIA

2.1 MATERIAL

A base de dados está organizada em quatro arquivos CSV. Três desses arquivos reúnem medições de parâmetros atmosféricos durante o ano de 2022 fragmentados em intervalos de mais ou menos 3 meses para o primeiro e segundo arquivos, e de quase 5 meses no último arquivo, todos apresentavam 11 colunas: Nome do Município, Estado, Nome da Estação, Item_monitorado (indica qual dos 37 parâmetros atmosféricos está sendo medido), Sigla (sigla do parâmetro), Concentracao, iqar, Data, Hora, Situação (códigos como VA — válido; IV ou IN — inválido) e uma coluna descritiva sem nome que aparecia como “Unnamed: 10” a qual registrava observações do motivo de invalidez do dado. O quarto arquivo armazenava informações específicas das estações de monitoramento em 12 colunas: Código IBGE do Município, Nome do Município, Estado, ID da Estação, Nome da Estação, Item medido (indica quais parâmetros atmosféricos diferentes a estação monitorou), Status da estação (Se estava em operação ou não), Tipo da estação, Latitude, Longitude, no_fonte_dados (instituição da qual a estação pertencia), e novamente uma coluna sem nome Unnamed: 11. Ao total, a base de dados continha 154 estações distribuídas em oito estados brasileiros.

Os registros de concentração faziam referência a 37 parâmetros atmosféricos diferentes, apresentados na figura 1, em que a medição foi em grande parte registrada de hora em hora, embora alguns parâmetros tenham sido registrados a cada 30 minutos. Cada estação mediu uma variedade diferente de parâmetros e além das colunas de concentração, também havia o cálculo do Índice de Qualidade do Ar (“iqar”) já fornecido pelo sistema.

Sigla	Nome do parâmetro	Unidade
ACETAL	Acetaldeído	µg/m³
BEN	Benzeno	µg/m³
BTEX	Benzeno, Tolueno, Etil-benzeno e Xileno	µg/m³
CH ₄	Metano	µg/m³
CO	Monóxido de Carbono	ppm
ERT	Enxofre Reduzido Total	µg/m³
Etil Benz	Etil-benzeno	µg/m³
FMC	Fumaça	µg/m³
FORMAL	Formaldeído	µg/m³
H ₂ S	Gás Sulfídrico	µg/m³
HCnM	Hidrocarbonetos não Metano	µg/m³
HCT	Hidrocarbonetos Totais	µg/m³
M e P Xileno	Meta e Para-xileno	µg/m³
MP ₁₀	Material Particulado com diâmetro de até 10 µm	µg/m³
MP _{2,5}	Material Particulado com diâmetro de até 2,5 µm	µg/m³
NH ₃	Amônia	µg/m³
NO	Óxido Nítrico	µg/m³
NO ₂	Dióxido de Nitrogênio	µg/m³
NOx	Óxidos de Nitrogênio	µg/m³
O ₃	Ozônio	µg/m³

Sigla	Nome do parâmetro	Unidade
Orto Xil	Orto-xileno	µg/m³
PTS	Partículas Totais em Suspensão	µg/m³
SO ₂	Dióxido de Enxofre	µg/m³
SOx	Óxidos de Enxofre	µg/m³
TOL	Tolueno	µg/m³
XIL	Xileno	µg/m³
CHO	Aldeídos	µg/m³
Pb	Chumbo	µg/m³
COV	Compostos Orgânicos Voláteis	µg/m³
TEMP	Temperatura	°C (graus Celsius)
VV	Velocidade do vento	Km/h
CH	Chuva	mm
U	Umidade	%
DV	Direção do vento	° (graus)
UR	Umidade relativa	%
RAD	Radiação solar	W/m²
PRESS	Pressão atmosférica	hPa (hectoPascal)

Figura 1: Parâmetros atmosféricos medidos e suas respectivas unidades de medição.

O cálculo do IQAR é feito com apenas seis poluentes, presentes na figura 2, seguindo o procedimento oficial adotado (conforme orientação normativa do CONAMA).

E para o cálculo do IQAR aplica-se a seguinte fórmula:

$$IQAR = I_{ini} + \frac{I_{fin} - I_{ini}}{C_{fin} - C_{ini}} \times (C - C_{ini})$$

Figura 2: Fórmula do Índice de Qualidade do Ar.

Onde:

I_{ini} — Valor do índice que corresponde à concentração inicial da faixa;

I_{fin} — Valor do índice que corresponde à concentração final da faixa;

C_{ini} — Concentração inicial da faixa em que se localiza a concentração medida;

C_{fin} — Concentração final da faixa em que se localiza a concentração medida;

C — Concentração medida do poluente.

Com a concentração medida, localiza-se na figura 3, as faixas de concentração inicial e final correspondentes ao poluente medido, e suas faixas de índice tabelados. Essa operação é realizada independentemente para cada um dos seis poluentes e o índice final atribuído à estação naquele instante será o maior resultado obtido entre esses seis índices calculados, de forma a refletir a condição mais crítica de qualidade do ar naquele período. É importante notar as peculiaridades de concentração consideradas no cálculo: para MP_{10} e $MP_{2,5}$ utiliza-se a média de 24 horas das concentrações; para O_3 considera-se a concentração máxima expressa pela média móvel de 8 horas (i.e., o maior valor da média de 8 horas); para NO_2 adota-se a máxima de 1 hora; para CO é usada a média de 8 horas; e para SO_2 a referência é tipicamente a média de 24 horas — janelas temporais que seguem as diretrizes técnicas e normativas adotadas para o IQAR no Brasil. Essas regras procedimentais e a escolha do maior IQAR final estão estabelecidas nas orientações do guia técnico de monitoramento do ar e nas resoluções normativas do CONAMA em documentos oficiais correlatos, que definem as faixas de concentração, as janelas temporais e os limites de referência para cada poluente.

Qualidade do Ar	Índice	MP_{10} ($\mu g/m^3$) 24h	$MP_{2,5}$ ($\mu g/m^3$) 24h	O_3 ($\mu g/m^3$) 8h	CO (ppm) 8h	NO_2 ($\mu g/m^3$) 1h	SO_2 ($\mu g/m^3$) 24h
N1 - Boa	0 - 40	0 - 50	0 - 25	0 - 100	0 - 9	0 - 200	0 - 20
N2 - Moderada	41 - 80	>50 - 100	>25 - 50	>100 - 130	>9 - 11	>200 - 240	>20 - 40
N3 - Ruim	81 - 120	>100 - 150	>50 - 75	>130 - 160	>11 - 13	>240 - 320	>40 - 365
N4 - Muito Ruim	121 - 200	>150 - 250	>75 - 125	>160 - 200	>13 - 15	>320 - 1130	>365 - 800
N5 - Péssima	201 - 400	>250 - 600	>125 - 300	>200 - 800	>15 - 50	>1130 - 3750	>800 - 2620

Figura 3: Valores de referência para o cálculo do IQAR.

Embora o procedimento acima descreva o cálculo do IQAR a partir das concentrações, não foi recalculado o IQAR durante o trabalho: o índice já se encontrava presente na base de dados fornecida (coluna iqar). Assim, as análises realizadas (exploração, séries temporais, comparação entre estações e modelagem) utilizaram o IQAR disponível, preservando a rastreabilidade da origem do índice e evitando discrepâncias por diferenças em tabelas de faixas ou convenções de arredondamento.

	Nome do Município	Estado	Nome da Estação	Item monitorado	Sigla	Concentracao	iqar	Data	Hora	Situação	Unnamed: 10
0	Conceição do Mato Dentro	MG	Aeroporto CMD	Material Particulado com diâmetro de até 10 µm	MP10	42.00	26.4	31/03/2022	23:30	VA	NaN
1	Conceição do Mato Dentro	MG	Aeroporto CMD	Material Particulado com diâmetro de até 2,5 µm	MP2,5	8.00	12.8	31/03/2022	23:30	VA	NaN
2	Conceição do Mato Dentro	MG	Aeroporto CMD	Partículas Totais em Suspensão	PTS	63.00	NaN	31/03/2022	23:30	VA	NaN
3	Barra Longa	MG	Barra Longa Centro	Material Particulado com diâmetro de até 10 µm	MP10	28.00	38.4	31/03/2022	23:30	VA	NaN
4	Barra Longa	MG	Barra Longa Centro	Material Particulado com diâmetro de até 2,5 µm	MP2,5	10.00	19.2	31/03/2022	23:30	VA	NaN
...	...	...	...	...	...	...	...	...	...	...	...
2300228	Rio de Janeiro	RJ	Tijuca	Umidade relativa	UR	84.73	NaN	01/07/2022	00:00	VA	NaN
2300229	Rio de Janeiro	RJ	Tijuca	Vento	VV	0.06	NaN	01/07/2022	00:00	VA	NaN
2300230	Triunfo	RS	TRIUNFO/POLO PETROQUÍMICO/MÓVEL	Dióxido de Enxofre	SO2	0.86	2.0	01/07/2022	00:00	VA	NaN
2300231	Triunfo	RS	TRIUNFO/POLO PETROQUÍMICO/MÓVEL	Dióxido de Nitrogênio	NO2	9.72	2.0	01/07/2022	00:00	VA	NaN
2300232	Triunfo	RS	TRIUNFO/POLO PETROQUÍMICO/MÓVEL	Monóxido de Carbono	CO	0.02	0.0	01/07/2022	00:00	VA	NaN

2300233 rows x 11 columns

Tabela 1: Recorte da base de dados com todos os registros das estações de monitoramento.




Figura 4: Mapa das estações distribuídas pelo Brasil.

index	Código IBGE do Município	Nome do Município	Estado	ID da Estação	Nome da Estação	Item medido	Status da estação	Tipo da estação	Latitude	Longitude	no_fonte_dados
0	2905701	Camapari	BA	182	AREIAS	SO ₂	Em Operação	Automática	-12,801148	-38,223995	CETREL e Inema
1	2905701	Camapari	BA	184	MACHADINHO	CH, CO, DV, NH ₃ , NO, NO ₂ , NO _x , O ₃ , PRESS, RAD, SO ₂ , TEMP, U, VV	Em Operação	Automática	-12,759957	-38,284080	CETREL e Inema
2	2905701	Camapari	BA	185	CÂMARA	DV, NO, NO ₂ , NO _x , O ₃ , SO ₂ , VV	Em Operação	Automática	-12,706030	-38,321377	CETREL e Inema
3	2905701	Camapari	BA	187	GRAVATÁ	CH, CH ₄ , CO, DV, ERT, HCT, MP ₁₀ , NH ₃ , NO, NO ₂ , NO _x , PRESS, RAD, SO ₂ , TEMP, U, VV	Em Operação	Automática	-12,686376	-38,333604	CETREL e Inema
4	2910057	Dias d'Ávila	BA	181	ESCOLA	CH, DV, ERT, NH ₃ , NO, NO ₂ , NO _x , O ₃ , PRESS, SO ₂ , TEMP, U, VV	Em Operação	Automática	-12,835318	-38,273178	CETREL e Inema
5	2910057	Dias d'Ávila	BA	183	CONCÓRDIA	DV, ERT, MP ₁₀ , NO, NO ₂ , NO _x , SO ₂ , VV	Em Operação	Automática	-12,804052	-38,325606	CETREL e Inema
6	2910057	Dias d'Ávila	BA	186	FUTURAMA I	ERT, SO ₂	Em Operação	Automática	-12,668989	-38,371572	CETREL e Inema
7	2910057	Dias d'Ávila	BA	188	LEANDRINHO	CH ₄ , DV, ERT, HCT, MP ₁₀ , MP _{2.5} , NO, NO ₂ , NO _x , SO ₂ , VV	Em Operação	Automática	-12,641589	-38,374871	CETREL e Inema
8	2910057	Dias d'Ávila	BA	190	COBRE	SO ₂	Em Operação	Automática	-12,630256	-38,358528	CETREL e Inema
9	2929503	São Sebastião do Passé	BA	189	LAMARÃO	CH, DV, ERT, NO, NO ₂ , NO _x , O ₃ , PRESS, RAD, SO ₂ , TEMP, U, VV	Em Operação	Automática	-12,595482	-38,398561	CETREL e Inema

Tabela 2: Descrição das estações de monitoramento do estado da Bahia.

2.2 MÉTODOS

O trabalho foi realizado em cinco diferentes etapas que foram o pré-processamento e tratamento dos dados, análise exploratória descritiva, modelagem de séries temporais, aplicação de técnicas de estimação de dados nas séries temporais, e, por fim, a avaliação estatística do desempenho dos métodos utilizados.

Como já foi descrito na parte de explicação do material, os dados brutos estavam divididos em três bases de dados distintas, onde foi necessário realizar uma filtragem dos registros do estado da Bahia para, após a seleção, juntar os três dataframes em um só com os dados de interesse do trabalho (o dataframe resultante está representado pela tabela 3). Procedendo a correção de formatação dos valores numéricos, identificando e ajustando inconsistências nos separadores decimais e de milhar (distinção entre ponto e vírgula), assegurando que os valores de concentração dos poluentes estivessem em suas grandezas corretas. Valores de IQAR classificados como inválidos foram removidos, e para a construção futura das séries temporais, valores simultâneos de IQAR em uma hora nas estações foram devidamente substituídas, conforme orientação oficial o guia técnico de monitoramento do ar, pelo valor máximo de IQAR naquela hora específica.

	Nome do Município	Estado	Nome da Estação	Item_monitorado	Sigla	Concentracao	iqar	Data	Hora	Situação	Unnamed: 10
0	Camaçari	BA	CÂMARA	Dióxido de Enxofre	SO2	0.421	2.60	31/03/2022	23:00	VA	Válido
1	Camaçari	BA	CÂMARA	Dióxido de Nitrogênio	NO2	17.368	4.36	31/03/2022	23:00	VA	Válido
2	Camaçari	BA	CÂMARA	Direção do vento	DV	141.608	NaN	31/03/2022	23:00	IV	Inválido
3	Camaçari	BA	CÂMARA	Óxido Nítrico	NO	5.104	NaN	31/03/2022	23:00	IV	Inválido
4	Camaçari	BA	CÂMARA	Óxidos de Nitrogênio	NOx	27.529	NaN	31/03/2022	23:00	IV	Inválido
...	...	...	...	...	...	...	...	...	...	...	...
611852	Camaçari	BA	MACHADINHO	Pressão atmosférica	PRESS	1015.063	NaN	01/07/2022	00:00	VA	NaN
611853	Camaçari	BA	MACHADINHO	Radiação solar	RAD	0.000	NaN	01/07/2022	00:00	VA	NaN
611854	Camaçari	BA	MACHADINHO	Temperatura	TEMP	19.746	NaN	01/07/2022	00:00	VA	NaN
611855	Camaçari	BA	MACHADINHO	Umidade	U	92.988	NaN	01/07/2022	00:00	VA	NaN
611856	Camaçari	BA	MACHADINHO	Vento	VV	0.329	NaN	01/07/2022	00:00	VA	NaN

611857 rows x 11 columns

Tabela 3: Recorte do dataframe com os dados do estado da Bahia.

Para compreender a distribuição e o comportamento dos dados, realizou-se uma análise da dispersão e da variabilidade do IQAR através de diagramas de caixa (*boxplots*), gerados para o conjunto total dos dados e em cada estação de monitoramento. Essa análise permitiu a identificação preliminar de valores discrepantes e a comparação da amplitude dos índices entre as diferentes estações. Adicionalmente, investigou-se a

influência relativa de cada poluente na composição do índice final por gráficos de setores para se observar a frequência com que cada poluente atuou como o poluente decisivo no valor final de IQAR, tanto em uma perspectiva global quanto individualizada por estação, e além disso foi feita uma simples análise da média total dos valores de IQAR por estação em que os resultados foram expressos em um gráfico de barras.

Os valores de IQAR foram organizados em séries temporais dos dados de hora em hora, em séries temporais das médias diárias e mensais. A estrutura de dependência temporal e a persistência dos fenômenos atmosféricos foram investigadas através das Funções de Autocorrelação (ACF) e Autocorrelação Parcial (PACF). Essas ferramentas foram importantes para diagnosticar a memória da série e ajudar na escolha dos parâmetros dos modelos de imputação. Para a validação estatística, foram criados intervalos artificiais de dados ausentes, removendo-se intencionalmente subconjuntos de dados reais proporcionais aos intervalos de dados ausentes reais presentes na base de dados. Esse procedimento permitiu que os métodos de estimação fossem aplicados sobre lacunas conhecidas, possibilitando o confronto direto entre os valores estimados e os valores reais da série histórica.

Foram experimentados diferentes métodos de estimação de séries temporais, e a eficiência desses métodos puderam ser medidos a partir de métricas de avaliação detalhados a seguir:

- Interpolação Linear: Estima o valor ausente assumindo uma variação constante entre dois pontos conhecidos (x_0, y_0) e (x_1, y_1) . A fórmula aplicada é:

$$y = y_0 + (x - x_0) \frac{y_1 - y_0}{x_1 - x_0}$$

Figura 5: Fórmula do método de Interpolação Linear.

- Interpolação Polinomial (Splines): Foram utilizados polinômios de graus superiores (ordem 2 e 3) que ajustaram uma curva suave aos dados. O objetivo é minimizar a curvatura da função de interpolação entre os nós conhecidos.

- Médias Móveis Ponderadas (Kernels): Calcula a estimativa $\hat{y}$ baseada na média dos vizinhos dentro de uma janela ω , onde cada vizinho recebe um peso baseado na sua distância ao ponto central. Foram configurados pesos iguais para o método de médias móveis ponderadas, para todos os elementos da janela de tempo considerada para a estimação.

$$\hat{y}_t = \frac{\sum_{i=-n}^n w_i y_{t+i}}{\sum w_i}$$

Figura 6: Fórmula do método de médias móveis ponderadas.

- Suavização Exponencial Ponderada (EWM): Atribui pesos que decrescem exponencialmente em relação ao passado, sendo definido pela relação recursiva:

$$y_t = (1 - \alpha)y_{t-1} + \alpha x_t$$

Figura 7: Fórmula do método de suavização exponencial ponderada.

- K-Nearest Neighbors (KNN): Estima o valor ausente identificando os k padrões mais similares em todo o histórico de dados, utilizando a Distância Euclidiana para determinar a vizinhança:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Figura 8: Fórmula do método KNN.

- SARIMAX: Modelo autorregressivo integrado de médias móveis com componentes sazonais e variáveis exógenas. Combina a autocorrelação de curto prazo com a sazonalidade (s) identificada na PACF:

$$\phi_p(B)\Phi_P(B^s)(1-B)^d(1-B^s)^D y_t = \theta_q(B)\Theta_Q(B^s)c_t$$

Figura 9: Fórmula do método SARIMAX.

Para examinar preliminarmente se os métodos de estimação espaciais iriam funcionar bem ou não, foram feitas algumas análises de correlação espacial:

- Correlação de Pearson entre pares de estações: Mediu a força e direção da relação linear entre duas séries temporais associadas a duas estações:

$$r_{ij} = \frac{\sum_{t \in T_{ij}} (x_i(t) - \bar{x}_i)(x_j(t) - \bar{x}_j)}{\sqrt{\sum_{t \in T_{ij}} (x_i(t) - \bar{x}_i)^2} \sqrt{\sum_{t \in T_{ij}} (x_j(t) - \bar{x}_j)^2}}$$

Figura 10: Fórmula correlação de Pearson.

- Correlação x distância por um correlograma empírico: Esse gráfico teve como objetivo verificar empiricamente se a correlação entre séries decresce com a distância (efeito de decaimento espacial).

O cálculo das distâncias foi feito pelo método haversine, que obtém a distância terrestre (arcodélica) entre pares de estações a partir de latitude/longitude para ligar correlação e proximidade espacial:

- Raiz do Erro Quadrático Médio (RMSE): Mede a magnitude do erro, penalizando severamente desvios de grande escala:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2}$$

Figura 11: Fórmula da RMSE.

- Erro Médio Absoluto (MAE): Indica a média da magnitude absoluta dos erros, sendo menos sensível a valores discrepantes que o RMSE:

$$MAE = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i|$$

Figura 12: Fórmula do MAE.

- Erro percentual absoluto médio simétrico (Symmetric Mean Absolute Percentage Error - sMAPE): Utilizado para avaliar o erro em termos percentuais, sendo robusto a valores próximos de zero:

$$sMAPE = \frac{100\%}{n} \sum_{i=1}^n \frac{|\hat{y}_i - y_i|}{(|\hat{y}_i| + |y_i|) / 2}$$

Figura 13: Fórmula do sMAPE.

- Erro Médio de Viés (MBE): Indica se o modelo tende a superestimar (valor positivo) ou subestimar (valor negativo) os dados:

$$MBE = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)$$

Figura 14: Fórmula do MBE.

- Índice de Concordância de Willmott (d): Mede o grau em que as previsões do modelo estão livres de erro. Varia de 0 (sem concordância) a 1 (concordância perfeita):

$$d = 1 - \frac{\sum_{i=1}^n (\hat{y}_i - y_i)^2}{\sum_{i=1}^n (|\hat{y}_i - \bar{y}| + |y_i - \bar{y}|)^2}$$

Figura 15: Fórmula da índice de concordância de willmott.

- Eficiência de Nash-Sutcliffe (NSE): Compara a variância dos erros do modelo com a variância dos dados observados:

$$NSE = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Figura 16: Fórmula de NSE.

3. RESULTADOS E DISCUSSÃO

A dispersão e a variabilidade dos valores IQAR em toda base de dados pode ser observada abaixo:




Figura 17: Boxplot de todos valores de IQAR

A mediana do IQAR é igual a 12,0, indicando que 50% das observações apresentam valores iguais ou inferiores a esse nível. Observa-se que os valores variam aproximadamente de 0 a 300, com forte assimetria. O boxplot apresenta uma grande dispersão dos dados com numerosos valores extremos.

A análise dos gráficos de dispersão por estação de monitoramento indica que, na maioria das estações, persiste uma elevada variabilidade dos valores observados, com exceção da estação MACHADINHO. Algumas observações interessantes a serem feitas são que a estação Escola registra o maior valor de IQAR entre todas as estações (por volta de 300 de IQAR), e a estação AREIAS apresenta muitos dados ausentes de IQAR, o que compromete a robustez das análises estatísticas; por esse motivo, essa estação será excluída das análises subsequentes.




Figura 18: Gráficos Boxplot de cada uma das estações de monitoramento.

Nos gráficos de setores, os poluentes que mais influenciaram para determinar os valores de IQAR em todo o dataframe foram o Ozônio, seguido do Dióxido de Enxofre e em terceiro tem o Material Particulado com diâmetro de até 10 μm , as respectivas porcentagens estão presentes na figura X.

Gráfico em Setores dos poluentes de maior influência




Figura 19: Gráfico de Setores de todos poluentes que ditaram o valor de IQAR.

Ao realizar uma análise mais detalhada por estação de monitoramento, observa-se que os poluentes ozônio (O_3) e o Material Particulado com diâmetro de até 10 µm (MP_{10}) alternam-se para determinar o valor do final de IQAR nas diferentes estações. Esse comportamento é preocupante, por não haver nenhuma estação que realize o monitoramento simultâneo desses dois poluentes. Na realidade, nenhuma estação dispõe do conjunto completo de poluentes necessários para a caracterização integral da qualidade do ar, o que introduz incertezas na estimativa do IQAR e dificulta a determinação de um valor que represente de forma mais fidedigna a condição real da qualidade do ar em cada local.

Parâmetros mais influentes para o valor de IQAR




Figura 20: Gráfico de Setores das estações dos poluentes que ditaram o valor de IQAR.

O gráfico das médias de IQAR está disposto a seguir. A estação com maior média é a estação.




Figura 21: Gráficos das médias de IQAR em todas as estações de monitoramento.

Após organizar os dados em séries temporais, foram feitas as suas visualizações, em hora por hora, médias diárias e as médias por mês:




Figura 22: Gráficos das séries temporais horária, média diária, e da média mensal.

Uma inspeção visual das séries temporais denuncia a ocorrência de diversos intervalos de dados ausentes ao longo do período estudado, os quais se tornam mais perceptíveis nas séries das médias diárias, quando os intervalos passam de 24 horas. Parte desses intervalos ocorreram de forma simultânea em todas as estações de monitoramento, no total, foram identificados 21 intervalos de dados ausentes em comum entre as estações, somando 401 horas sem registros simultâneos. Destacam-se períodos

prolongados, como o intervalo de 15/06/2022 a 18/06/2022 (77 h), que se trata do largo intervalo sem dados das séries.

Para aplicar os métodos de estimação é importante antes compreender a estrutura temporal dos dados, buscando padrões, sazonalidade e tendências. Para isso foram aplicadas as Funções de Autocorrelação (ACF), levando em consideração uma janela de tempo de 168 horas de análise (uma semana), e Autocorrelação Parcial (PACF), em um intervalo de 12 horas.

A análise das funções de autocorrelação (ACF) e autocorrelação parcial (PACF) evidencia que o IQAR apresenta uma dependência temporal nas estações analisadas. O PACF indica memória curta, com picos significativos nos lags 1 e 2, sugerindo um comportamento autorregressivo de ordem baixa (AR(1) ou AR(2)), o que justifica o uso de métodos de imputação baseados em observações próximas no tempo, como médias móveis e suavização exponencial.

Já ACF revela um decaimento lento das correlações e presença de uma fraca sazonalidade que parece ser diária em diversas estações, com excessão de MACHADINHO. Esses padrões podem exigir um modelo mais robusto, como o SARIMAX com componente sazonal e o Filtro de Kalman, capazes de capturar tanto a sazonalidade quanto a inércia de longo prazo do sistema.




Figura 23: Gráficos do ACF e PACF.

Outra análise de correlação importante é a espacial, onde antes foi feita a matriz de correlação de Pearson entre as estações




Figura 24: Gráfico dos resultados das correlações de Pearson entre as estações.

A maioria dos pares tem correlação fraca a moderada (valores ≈ 0 a 0.2), com exceção de MACHADINHO com a estação CÂMARA de aproximadamente 0.65 de correlação, outra relativa correlação é a de MACHADINHO com ESCOLA de 0.51.

Entretanto, só a correlação de Pearson não seria suficiente para analisar alguma relação espacial entre os dados, por isso foi feito o gráfico de scatter correlação (Pearson) versus distância geográfica, além do gráfico de correlograma empírico.

Não é observado decaimento claro e consistente da correlação com o aumento da distância entre as estações. A linha de tendência mostra uma leve queda em distâncias

curtas e depois leve recuperação, um comportamento oscilante confuso. Isto pode estar sugerindo influência de fatores não só espaciais.




Figura 25: Gráfico de correlação de Pearson x distância entre as estações.




Figura 26: Gráfico do correlograma empírico.

O correlograma empírico reforça essa conclusão ao mostrar médias de correlação próximas de zero em diferentes faixas de distância, acompanhadas de elevada variabilidade interna, o que aponta para a ausência de um alcance espacial bem definido

Para avaliar os métodos de estimação, propositalmente foram criadas lacunas artificiais desenhadas para replicar fielmente a estrutura e a proporção de dados ausentes observada originalmente em cada estação. Para os intervalos de dados ausentes, reproduziu-se em cada coluna (estação) a mesma quantidade e extensão de horas omissas encontradas nos hiatos reais, posicionando-os em trechos de dados íntegros a distâncias temporais controladas para garantir que a avaliação ocorresse em contextos meteorológicos análogos aos das falhas originais. O critério de deslocamento foi rigorosamente definido pelo comprimento do intervalo: lacunas de 2h a 6h foram posicionadas a 1 hora de distância do gap real; janelas de 7h a 12h foram deslocadas em 6h; intervalos entre 13h e 24h mantiveram uma distância de 12h; e para falhas superiores a 24h, adotou-se um afastamento de um dia completo (24h) em relação ao registro original. Complementarmente, foram retirados registros pontuais aleatórios na série temporal, visando aferir a precisão dos métodos de estimação tanto na reconstrução de eventos isolados quanto na recuperação de tendências em períodos de interrupção prolongada do monitoramento.




Figura 27: Gráfico da série temporal com as lacunas artificiais.

Finalmente após aplicar os métodos de estimação obteve-se a tabela a seguir:

Método	RMSE	MAE	sMAPE (%)	Bias (MBE)	Willmott (d)	NSE
Interpolação Linear	6.547	1.520	15.559	-0.140	0.925	0.749
Interpolação Polinomial (ord. 2)	7.925	2.459	28.163	0.166	0.897	0.633
Interpolação Polinomial (ord. 3)	7.460	2.553	30.652	0.360	0.904	0.674
Média Móvel Exponencial Ponderada	7.519	2.376	25.059	-0.096	0.898	0.669
KNN Imputer (Espacial)	8.212	2.858	27.921	-0.255	0.870	0.605
SARIMAX (ARIMA)	6.937	1.977	22.583	-0.401	0.908	0.718

Tabela 4: Resultados dos métodos de estimação.

Os resultados da avaliação mostram que os métodos temporais simples apresentaram o melhor desempenho geral, enquanto a técnica espacial (KNN Imputer) foi a que teve pior desempenho entre os avaliados. A interpolação linear obteve o menor erro (RMSE = 6.547; MAE = 1.520) e o menor sMAPE ($\approx 15.6\%$), resultando também no maior NSE (≈ 0.75) e em boa concordância segundo o índice de Willmott; portanto, para os gaps e a janela temporal deste conjunto de dados, uma interpolação temporal direta provou ser a estratégia mais eficaz. O modelo SARIMAX foi o segundo melhor em termos de RMSE (≈ 6.937) e apresentou bom comportamento (MAE ≈ 1.98 ; NSE ≈ 0.72), o que indica que modelos autorregressivos com componente sazonal capturam parte da dinâmica temporal útil para imputação. Métodos polinomiais de ordem 2 e 3 mostraram maior erro e sMAPE elevado, sugerindo sobreajuste e oscilações indesejadas em intervalos de imputação; a média móvel exponencial ponderada teve desempenho intermédio, com erro superior ao da interpolação linear, mas melhor que os polinômios em algumas métricas. A performance inferior do KNN espacial (RMSE ≈ 8.21 , MAE ≈ 2.86) era esperada dado o fraco sinal espacial observado nas análises anteriores: quando a correlação entre vizinhos é fraca ou heterogênea, métodos puramente espaciais tendem a aportar pouca informação útil e podem até degradar as estimativas. Em síntese, para lacunas de curta a média duração neste conjunto, soluções temporais (especialmente interpolação linear e modelos ARIMA/SARIMAX) mostram-se mais robustas; a integração criteriosa de informação espacial só é recomendada quando houver evidência clara de dependência espacial consistente entre estações.

4. CONCLUSÃO

A análise conduzida permitiu avaliar o desempenho de diferentes algoritmos na recuperação de dados ausentes, mas, acima de tudo, revelou fragilidades estruturais no monitoramento da qualidade do ar nas regiões estudadas. O ponto mais crítico identificado é que o cálculo do IQAR baseia-se no princípio do poluente mais crítico entre os seis monitorados; no entanto, a ausência de medições completas para todo o espectro de poluentes em uma única estação impede a determinação do valor real e definitivo do índice. Essa lacuna instrumental torna o IQAR final inconclusivo, uma vez que o poluente que ditaria a qualidade do ar naquele instante pode simplesmente não ter sido medido.

Quanto ao desempenho dos métodos de estimação frente aos gaps artificiais criados para simulação, os resultados demonstram que a Interpolação Linear obteve a maior concordância estatística, com um Índice de Willmott de 0,925 e o menor RMSE (6,547). Este resultado é corroborado pelas análises de PACF, que mostraram uma dependência extrema da série em relação ao seu passado imediato (Lag 1). Modelos mais complexos, como o SARIMAX, embora capturem a sazonalidade diária, apresentaram um viés de subestimação mais acentuado (MBE = -0,401).

Em conclusão, embora a Interpolação Linear tenha se mostrado a ferramenta mais precisa para lidar com a variabilidade das séries tratadas, a utilidade prática dessas estimativas permanece limitada pela incompletude dos dados originais. Recomenda-se que futuras expansões da rede de monitoramento na Bahia priorizem a instalação de sensores capazes de medir simultaneamente os seis poluentes em cada estação, permitindo que as técnicas de imputação aqui testadas operem sobre uma base de dados que reflita, de fato, a realidade da qualidade do ar.

5. REFERÊNCIAS BIBLIOGRÁFICAS

Norma da ABNT

1. World Health Organization (WHO). (2021). *WHO global air quality guidelines: particulate matter (PM_{2.5} and PM₁₀), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide*. Geneva: WHO.
2. BRASIL. Governo Federal. Ar Puro MonitorAr: dados de monitoramento da qualidade do ar. Disponível em:
<https://dados.gov.br/dados/conjuntos-dados/ar-puro-monitorar>. Acesso em: 19 dez. 2025.
3. BRASIL. Ministério do Meio Ambiente. Secretaria de Qualidade Ambiental. Guia técnico para o monitoramento e avaliação da qualidade do ar. Brasília, DF: MMA, 2020. 136 p. Disponível em:
<https://www.mma.gov.br/agenda-ambiental-urbana/qualidade-do-ar.html>. Acesso em: 19 dez. 2025.

6. APÊNDICE/ANEXO